

大光圈实验记录

由 安世杰创建, 最后修改于昨天4:12 下午

11.26-12.03

1、工作总结

- 1) 在纯人数据集上测试小模型的结果，小模型效果较差，大模型压缩到100M，在纯人数据上表现与原始模型相差不大，场景数据上效果有所下降。
- 2) 下一步，继续缩减模型decoder部分的计算量，预计可以压缩至70M。

2、实验结果

model	nyu	CAD	URFall	config	sample
1、mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-upcat-person	rmse: 0.4738 berhu: 0.2690 grad: 0.0715 norm: 0.0075 mrel: 0.1063	rmse: 0.2389 berhu: 0.1082 grad: 0.0794 norm: 0.0068 mrel: 0.0451	rmse: 0.2296 berhu: 0.1085 grad: 0.0794 norm: 0.0065 mrel: 0.0342	baseline模型，162M 已导出模型1204	Shuffle
2、mobilenet-v1-quant-128x160-conv_dw0.5-sum	rmse: 0.6678 berhu: 0.4290 grad: 0.0749 norm: 0.0081 mrel: 0.1837	rmse: 0.3412 berhu: 0.1686 grad: 0.0808 norm: 0.0077 mrel: 0.0691	rmse: 0.4254 berhu: 0.2238 grad: 0.0807 norm: 0.0075 mrel: 0.0641	上采样加和，107M	Shuffle
3、mobilenet-v1-quant-128x160-conv_dw0.5-srfl-resnet	rmse: 0.7763 berhu: 0.5165 grad: 0.0755 norm: 0.0083 mrel: 0.2371	rmse: 0.6426 berhu: 0.3687 grad: 0.0820 norm: 0.0080 mrel: 0.1369	rmse: 0.3924 berhu: 0.1965 grad: 0.0799 norm: 0.0073 mrel: 0.0571	同上 conv-dw换成res block，107M	Sampler
4、mobilenet-v1-quant-128x160-conv_dw0.5-small	rmse: 0.8404 berhu: 0.5680 grad: 0.0776 norm: 0.0084 mrel: 0.2575	rmse: 0.6045 berhu: 0.3309 grad: 0.0808 norm: 0.0078 mrel: 0.1289	rmse: 0.4579 berhu: 0.2374 grad: 0.0811 norm: 0.0076 mrel: 0.0689	同上 无upconv，73M	shuffle
5、mobilenet-v1-quant-128x160-conv_dw0.5-small-fpn	rmse: 0.9245 berhu: 0.6285 grad: 0.0868 norm: 0.0097 mrel: 0.2775	rmse: 0.5360 berhu: 0.3001 grad: 0.0838 norm: 0.0080 mrel: 0.1243	rmse: 0.3861 berhu: 0.1900 grad: 0.0803 norm: 0.0073 mrel: 0.0560	同上 layer3-4换成PSP 加face++版SE 93M	Sampler
6、mobilenet-v1-quant-128x160-conv_dw0.5-fpn	rmse: 0.7886 berhu: 0.5256 grad: 0.0764 norm: 0.0084 mrel: 0.2376	rmse: 0.6121 berhu: 0.3346 grad: 0.0822 norm: 0.0080 mrel: 0.1350	rmse: 0.4185 berhu: 0.2022 grad: 0.0803 norm: 0.0073 mrel: 0.0563	同3 加face++版SE 108M	Sampler
7、mobilenet-v1-quant-128x160-conv_dw-person-50M	rmse: 0.7367 berhu: 0.4825 grad: 0.0735 norm: 0.0080 mrel: 0.2098	rmse: 0.2868 berhu: 0.1357 grad: 0.0794 norm: 0.0071 mrel: 0.0569	rmse: 0.4025 berhu: 0.2031 grad: 0.0796 norm: 0.0074 mrel: 0.0599	同1 layer3的conv-dw减少，其他没变 150M	shuffle
8、mobilenet-v1-quant-128x160-conv_dw-person-psp	rmse: 0.9674 berhu: 0.6693 grad: 0.0770 norm: 0.0084 mrel: 0.3104	rmse: 0.5112 berhu: 0.2921 grad: 0.0832 norm: 0.0081 mrel: 0.1272	rmse: 0.4104 berhu: 0.2035 grad: 0.0806 norm: 0.0075 mrel: 0.0608	同1 layer3-4换成PSP 152M	Sampler
9、mobilenet-v1-quant-128x160-conv_dw0.5-sum-skip-fpn	rmse: 0.8390 berhu: 0.5660 grad: 0.0777 norm: 0.0084 mrel: 0.2569	rmse: 0.5319 berhu: 0.2847 grad: 0.0824 norm: 0.0078 mrel: 0.1210	rmse: 0.4920 berhu: 0.2733 grad: 0.0812 norm: 0.0076 mrel: 0.0731	同4 加skip和face++版SE 98M	shuffle
10、mobilenet-v1-quant-128x160-conv_dw0.5-upcat-predict-up	rmse: 0.4753 berhu: 0.2746 grad: 0.0779 norm: 0.0080 mrel: 0.1086	rmse: 0.2173 berhu: 0.1058 grad: 0.0912 norm: 0.0083 mrel: 0.0427	rmse: 0.1891 berhu: 0.0993 grad: 0.0870 norm: 0.0074 mrel: 0.0306	同1 先卷积在上采样输出 159M	Sampler
11、mobilenet-v1-quant-128x160-conv_dw0.25-person	rmse: 0.5848 berhu: 0.3486 grad: 0.0749 norm: 0.0082 mrel: 0.1449	rmse: 0.3453 berhu: 0.1673 grad: 0.0818 norm: 0.0078 mrel: 0.0683	rmse: 0.2479 berhu: 0.1092 grad: 0.0786 norm: 0.0066 mrel: 0.0348	同1 0.25版本模型 48M	sampler
12、mobilenet-v1-quant-128x160-conv_dw0.5-160M-se	rmse: 0.5019 berhu: 0.2973 grad: 0.0774 norm: 0.0079 mrel: 0.1179	rmse: 0.2270 berhu: 0.1132 grad: 0.0888 norm: 0.0079 mrel: 0.0456	rmse: 0.1942 berhu: 0.1038 grad: 0.0851 norm: 0.0071 mrel: 0.0319	同1 加了SE模块finetune 162M	Sampler
13、mobilenet-v1-quant-128x160-conv_dw0.5-160M-se-freeze	rmse: 0.5050 berhu: 0.2979 grad: 0.0721 norm: 0.0076 mrel: 0.1190	rmse: 0.2614 berhu: 0.1268 grad: 0.0815 norm: 0.0071 mrel: 0.0531	rmse: 0.2410 berhu: 0.1174 grad: 0.0793 norm: 0.0065 mrel: 0.0375	同12 固定部分参数只finetuneSE模块 162M	Sampler
14、mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-reduce-ch4	rmse: 0.6651 berhu: 0.4172 grad: 0.0805 norm: 0.0082 mrel: 0.1680	rmse: 0.3003 berhu: 0.1590 grad: 0.0926 norm: 0.0084 mrel: 0.0605	rmse: 0.2769 berhu: 0.1441 grad: 0.0911 norm: 0.0082 mrel: 0.0439	同1 减少layer3的conv-dw次数，减少一半layer4的channel数 128M	

15、mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-upcat-reduce-ch4	rmse: 0.5664 berhu: 0.3485 grad: 0.0833 norm: 0.0084 mrel: 0.1416	rmse: 0.2951 berhu: 0.1746 grad: 0.0985 norm: 0.0093 mrel: 0.0749	rmse: 0.2394 berhu: 0.1508 grad: 0.0935 norm: 0.0082 mrel: 0.0488	layer4通道数减少一半 152M	
16、mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-reduce-layer3	rmse: 0.7726 berhu: 0.5141 grad: 0.0840 norm: 0.0085 mrel: 0.2257	rmse: 0.3574 berhu: 0.1957 grad: 0.0942 norm: 0.0087 mrel: 0.0782	rmse: 0.2867 berhu: 0.1452 grad: 0.0910 norm: 0.0081 mrel: 0.0447	同1 减少layer3的conv-dw次数 136M	
17、mobilenet-v1-quant-128x160-conv_dw0.5-new	rmse: 0.9608 berhu: 0.6562 grad: 0.0914 norm: 0.0096 mrel: 0.2929	rmse: 0.5738 berhu: 0.3284 grad: 0.0927 norm: 0.0085 mrel: 0.1367	rmse: 0.3106 berhu: 0.1528 grad: 0.0897 norm: 0.0078 mrel: 0.0471	小模型baseline 52M	Sampler
18、mobilenet-v1-quant-128x160-conv_dw0.5-new-dec	rmse: 0.7614 berhu: 0.4848 grad: 0.0815 norm: 0.0086 mrel: 0.2097	rmse: 0.5630 berhu: 0.3231 grad: 0.0911 norm: 0.0094 mrel: 0.1389	rmse: 0.4684 berhu: 0.2525 grad: 0.0826 norm: 0.0081 mrel: 0.1175	同11 encoder和15一样, layer3减少dw次数 48M	
19、mobilenet-v1-quant-64x80-conv_dw0.5-upcat	rmse: 0.8942 berhu: 0.6078 grad: 0.1675 norm: 0.0209 mrel: 0.2711	rmse: 0.8193 berhu: 0.5310 grad: 0.1728 norm: 0.0217 mrel: 0.2248	rmse: 0.6699 berhu: 0.4166 grad: 0.1434 norm: 0.0161 mrel: 0.2095	同1 输入64x80, 去掉layer4 60M	
20、mobilenet-v1-quant-128x160-conv_dw0.5-upcat-predict-up-first-dw	rmse: 0.5971 berhu: 0.3750 grad: 0.0723 norm: 0.0079 mrel: 0.1542	rmse: 0.5468 berhu: 0.3193 grad: 0.0799 norm: 0.0088 mrel: 0.1295	rmse: 0.4966 berhu: 0.2784 grad: 0.0692 norm: 0.0073 mrel: 0.1239	同10 将第一层换成conv_dw 154M	
21 mobilenet-v1-quant-128x160-conv_dw0.5-upcat-predict-up-reorg	rmse: 0.9576 berhu: 0.6401 grad: 0.0900 norm: 0.0089 mrel: 0.2594	rmse: 0.8632 berhu: 0.5438 grad: 0.1013 norm: 0.0103 mrel: 0.1995	rmse: 0.7467 berhu: 0.4717 grad: 0.0858 norm: 0.0081 mrel: 0.1915	同10 把stride=2的卷积用Reorg 193M	

目前实验结果没有比当前模型好的, model 1可以作为当前最好的baseline, 而model 4可作为小模型的baseline。

0、mobilenet-v1-quant-128x160-conv_dw0.5-upcat-predict-up	rmse: 0.4753 berhu: 0.2746 grad: 0.0779 norm: 0.0080 mrel: 0.1086	rmse: 0.2173 berhu: 0.1058 grad: 0.0912 norm: 0.0083 mrel: 0.0427	rmse: 0.1891 berhu: 0.0993 grad: 0.0870 norm: 0.0074 mrel: 0.0306	同1 先卷积在上采样输出 159M	
1、mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-upcat-person	rmse: 0.4738 berhu: 0.2690 grad: 0.0715 norm: 0.0075 mrel: 0.1063	rmse: 0.2389 berhu: 0.1082 grad: 0.0794 norm: 0.0068 mrel: 0.0451	rmse: 0.2296 berhu: 0.1085 grad: 0.0794 norm: 0.0065 mrel: 0.0342	baseline模型, 162M	
2、mobilenet-v1-quant-128x160-conv_dw0.25-person	rmse: 0.5848 berhu: 0.3486 grad: 0.0749 norm: 0.0082 mrel: 0.1449	rmse: 0.3453 berhu: 0.1673 grad: 0.0818 norm: 0.0078 mrel: 0.0683	rmse: 0.2479 berhu: 0.1092 grad: 0.0786 norm: 0.0066 mrel: 0.0348	同1 0.25版本模型 48M	
	rmse: 0.6038 berhu: 0.3584 grad: 0.0908 norm: 0.0097 mrel: 0.1452	rmse: 0.2578 berhu: 0.1084 grad: 0.0956 norm: 0.0090 mrel: 0.0422	rmse: 0.1752 berhu: 0.0740 grad: 0.0888 norm: 0.0075 mrel: 0.0219	同上 迭代次数更多	
3 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-reduce-ch4	rmse: 0.5208 berhu: 0.3039 grad: 0.0851 norm: 0.0088 mrel: 0.1206	rmse: 0.2042 berhu: 0.0895 grad: 0.0922 norm: 0.0083 mrel: 0.0359	rmse: 0.1620 berhu: 0.0739 grad: 0.0864 norm: 0.0072 mrel: 0.0227	同1 减少layer3的conv-dw次数, 减少一半layer4的channel数 128M	
4 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-reduce-layer3	rmse: 0.5546	rmse: 0.2167	rmse: 0.1765	同1	

	grad: 0.0871 norm: 0.0089 mrel: 0.1354	grad: 0.0937 norm: 0.0086 mrel: 0.0407	grad: 0.0888 norm: 0.0075 mrel: 0.0266	
5 mobilenet-v1-quant-128x160-conv_dw0.5-simple	rmse: 0.5257 berhu: 0.3111 grad: 0.0869 norm: 0.0088 mrel: 0.1222	rmse: 0.2231 berhu: 0.1023 grad: 0.0954 norm: 0.0087 mrel: 0.0414	rmse: 0.1765 berhu: 0.0860 grad: 0.0903 norm: 0.0076 mrel: 0.0266	同1 decoder无upconv，直接smooth缩小四倍通道 114M
6 mobilenet-v1-quant-128x160-conv_dw0.5-sum	rmse: 0.5169 berhu: 0.3040 grad: 0.0828 norm: 0.0086 mrel: 0.1228	rmse: 0.2051 berhu: 0.0927 grad: 0.0902 norm: 0.0081 mrel: 0.0392	rmse: 0.1670 berhu: 0.0773 grad: 0.0854 norm: 0.0072 mrel: 0.0245	上采样加和，107M 在全数据上用了SGD finetune结果不变
7 mobilenet-v1-quant-128x160-conv_dw0.5-more-simple	rmse: 0.7195 berhu: 0.4676 grad: 0.0938 norm: 0.0091 mrel: 0.2026	rmse: 0.2730 berhu: 0.1307 grad: 0.0983 norm: 0.0091 mrel: 0.0529	rmse: 0.2055 berhu: 0.0989 grad: 0.0928 norm: 0.0079 mrel: 0.0302	同5， 将encoder中dw换成skip中的dw 107M
8 mobilenet-v1-quant-128x160-conv_dw0.5-upcat-se	rmse: 0.6500 berhu: 0.4260 grad: 0.0956 norm: 0.0093 mrel: 0.1783	rmse: 0.3052 berhu: 0.1844 grad: 0.1044 norm: 0.0091 mrel: 0.0769	rmse: 0.2705 berhu: 0.1587 grad: 0.1043 norm: 0.0089 mrel: 0.0497	有SE模型在全部数据上finetune 168M

- 1) 通过实验2的训练过程发现，场景数据NYU和有人数据存在一定的矛盾关系，导致随着训练的进行，有人数据loss下降，而NYU数据的loss上升，且场景预测视觉效果较差。
- 2) 发现encoder非常重要，encoder改动会有较大的loss上升。
- 3) 融合层sum相比concat要差一些，但是在纯人数据上结果相差不大，主要在nyu数据上loss会上升。

12.4-10

model	nyu	CAD	URFall	config
0 mobilenet-v1-quant-128x160-conv_dw-24-384-person	rmse: 0.6018 berhu: 0.3773 grad: 0.0755 norm: 0.0080 mrel: 0.1559	rmse: 0.2960 berhu: 0.1481 grad: 0.0864 norm: 0.0080 mrel: 0.0620	rmse: 0.2384 berhu: 0.1213 grad: 0.0826 norm: 0.0072 mrel: 0.0380	第一层 conv_bn到16 decoder前两 层channel SE 后三层空间SE 67M 新训模型加了 ScanNet数据
1 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-person	rmse: 0.6190 berhu: 0.3738 grad: 0.0828 norm: 0.0089 mrel: 0.1431	rmse: 0.2468 berhu: 0.1250 grad: 0.0917 norm: 0.0084 mrel: 0.0487	rmse: 0.2211 berhu: 0.1136 grad: 0.0885 norm: 0.0079 mrel: 0.0352	同上表中的 model 6 107M 新训模型加了 ScanNet数据
2 mobilenet-v1-quant-128x160-conv_dw0.5-upcat-suncg-res-person	rmse: 0.5682 berhu: 0.3495 grad: 0.0866 norm: 0.0088 mrel: 0.1434	rmse: 0.2286 berhu: 0.1116 grad: 0.0946 norm: 0.0085 mrel: 0.0460	rmse: 0.1853 berhu: 0.0920 grad: 0.0897 norm: 0.0076 mrel: 0.0287	conv-dw换成 res block 并减少layer3 卷积数 138M

3 mobilenet-v1-quant-128x160-conv_dw0.5-upcat-suncg-res-person-se	rmse: 0.5499 berhu: 0.3360 grad: 0.0769 norm: 0.0079 mrel: 0.1345	rmse: 0.2594 berhu: 0.1261 grad: 0.0873 norm: 0.0079 mrel: 0.0514	rmse: 0.2030 berhu: 0.1007 grad: 0.0842 norm: 0.0070 mrel: 0.0308	同2 c5, p4是 channel SE, p2, p1是空间 SE, 均为 1+SE 138M
4 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-person	rmse: 0.5014 berhu: 0.2891 grad: 0.0754 norm: 0.0079 mrel: 0.1133	rmse: 0.2190 berhu: 0.0999 grad: 0.0849 norm: 0.0076 mrel: 0.0409	rmse: 0.1782 berhu: 0.0853 grad: 0.0816 norm: 0.0067 mrel: 0.0261	同1 在NYU和全 人上训练 107M
5 mobilenet-v1-quant-128x160-conv_dw0.5-upcat-suncg-res-person-se3	rmse: 0.5597 berhu: 0.3446 grad: 0.0872 norm: 0.0087 mrel: 0.1411	rmse: 0.2252 berhu: 0.1099 grad: 0.0954 norm: 0.0086 mrel: 0.0448	rmse: 0.1875 berhu: 0.0967 grad: 0.0902 norm: 0.0076 mrel: 0.0304	同3 p3也加空间 1+SE 138M
6 mobilenet-v1-quant-128x160-conv_dw0.5-upcat-suncg-res-person-se-no-one	rmse: 0.5436 berhu: 0.3334 grad: 0.0768 norm: 0.0079 mrel: 0.1372	rmse: 0.2650 berhu: 0.1320 grad: 0.0875 norm: 0.0080 mrel: 0.0551	rmse: 0.2070 berhu: 0.1046 grad: 0.0844 norm: 0.0071 mrel: 0.0322	同5 原始的SE 138M
7 mobilenet-v1-quant-128x160-conv_dw0.5-upcat-suncg-res-person-se-sum	rmse: 0.5695 berhu: 0.3504 grad: 0.0885 norm: 0.0088 mrel: 0.1435	rmse: 0.2433 berhu: 0.1135 grad: 0.0968 norm: 0.0089 mrel: 0.0462	rmse: 0.1963 berhu: 0.0967 grad: 0.0917 norm: 0.0078 mrel: 0.0304	同5 1+SE, cat换 为sum 109M
8 mobilenet-v1-quant-128x160-conv_dw0.5-upcat-suncg-res-person-1-se	rmse: 0.5565 berhu: 0.3417 grad: 0.0874 norm: 0.0087 mrel: 0.1395	rmse: 0.2237 berhu: 0.1076 grad: 0.0954 norm: 0.0086 mrel: 0.0437	rmse: 0.1831 berhu: 0.0907 grad: 0.0902 norm: 0.0076 mrel: 0.0285	同5 p4-3channel 1-SE p3-1空间 1+SE 138M
9、mobilenet-v1-quant-128x160-conv_dw-24-384-person	rmse: 0.5720 berhu: 0.3460 grad: 0.0756 norm: 0.0080 mrel: 0.1401	rmse: 0.2814 berhu: 0.1356 grad: 0.0860 norm: 0.0079 mrel: 0.0563	rmse: 0.2229 berhu: 0.1106 grad: 0.0826 norm: 0.0071 mrel: 0.0343	同0 纯人模型 只在NYU和人 数据上训练
10、mobilenet-v1-quant-128x160-conv_dw-24-384-general	rmse: 0.6261 berhu: 0.3942 grad: 0.0753 norm: 0.0080 mrel: 0.1643	rmse: 0.2775 berhu: 0.1310 grad: 0.0855 norm: 0.0079 mrel: 0.0544	rmse: 0.2394 berhu: 0.1235 grad: 0.0830 norm: 0.0071 mrel: 0.0394	同0 通用模型

可以发现，模型继续压缩会导致效果变差，模型的各种SE模块实际上相差不大，原始的SE可能会好一些。此外，即使是NYU和全人数据也会有很大的分布差异，因此，随着全人数据loss的降低，NYU的loss会上升。

12.10-17

在进行了数据分析之后对训练数据进行筛选之后再各个模型上的训练结果

model	nyu	CAD	URFall	config
-------	-----	-----	--------	--------

0 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-general	rmse: 0.4325 berhu: 0.2744 grad: 0.0669 norm: 0.0065 mrel: 0.1185	rmse: 0.2021 berhu: 0.1015 grad: 0.0830 norm: 0.0072 mrel: 0.0408	rmse: 0.1556 berhu: 0.0792 grad: 0.0748 norm: 0.0057 mrel: 0.0252	同上表中4 在新数据上训练, mask为1-107M
1 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-general-se	rmse: 0.4331 berhu: 0.2722 grad: 0.0744 norm: 0.0071 mrel: 0.1176	rmse: 0.1796 berhu: 0.0836 grad: 0.0901 norm: 0.0080 mrel: 0.0323	rmse: 0.1446 berhu: 0.0655 grad: 0.0796 norm: 0.0063 mrel: 0.0202	同0 p1-4加了1-SE, p1-2加了空
2 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-general-res	rmse: 0.5077 berhu: 0.3330 grad: 0.0791 norm: 0.0073 mrel: 0.1511	rmse: 0.1995 berhu: 0.0977 grad: 0.0932 norm: 0.0083 mrel: 0.0376	rmse: 0.1578 berhu: 0.0761 grad: 0.0822 norm: 0.0064 mrel: 0.0240	同0 将conv-dw换成res block
3 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-general-res2	rmse: 0.5067 berhu: 0.3292 grad: 0.0783 norm: 0.0073 mrel: 0.1452	rmse: 0.2045 berhu: 0.0995 grad: 0.0934 norm: 0.0085 mrel: 0.0395	rmse: 0.1600 berhu: 0.0766 grad: 0.0824 norm: 0.0065 mrel: 0.0242	同2 res block做两次3x3channel
4 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-general-se-origin	rmse: 0.4269 berhu: 0.2686 grad: 0.0749 norm: 0.0072 mrel: 0.1146	rmse: 0.1752 berhu: 0.0835 grad: 0.0889 norm: 0.0077 mrel: 0.0324	rmse: 0.1414 berhu: 0.0682 grad: 0.0785 norm: 0.0060 mrel: 0.0217	同0 c5、p4是channel SE, p1-2
5 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-general-psp	rmse: 0.5542 berhu: 0.3717 grad: 0.0840 norm: 0.0076 mrel: 0.1673	rmse: 0.2093 berhu: 0.1060 grad: 0.0953 norm: 0.0085 mrel: 0.0415	rmse: 0.1634 berhu: 0.0808 grad: 0.0830 norm: 0.0065 mrel: 0.0256	同0 将encoder后两层换成PSP核
6 mobilenet-v1-quant-128x160-conv_dw-24-384-general	rmse: 0.4836 berhu: 0.3170 grad: 0.0678 norm: 0.0067 mrel: 0.1415	rmse: 0.2385 berhu: 0.1234 grad: 0.0856 norm: 0.0077 mrel: 0.0494	rmse: 0.1768 berhu: 0.0923 grad: 0.0768 norm: 0.0061 mrel: 0.0293	同上表9, 10 在新数据上训练
7 mobilenet-v1-quant-128x160-conv_dw-24-384-person	rmse: 0.4524 berhu: 0.2882 grad: 0.0689 norm: 0.0067 mrel: 0.1222	rmse: 0.2250 berhu: 0.1129 grad: 0.0859 norm: 0.0077 mrel: 0.0454	rmse: 0.1681 berhu: 0.0847 grad: 0.0767 norm: 0.0061 mrel: 0.0270	同6 只在NYU和人数据上训练
8 mobilenet-v1-quant-128x160-conv_dw0.25-person	rmse: 0.5903 berhu: 0.3480 grad: 0.0894 norm: 0.0096 mrel: 0.1414	rmse: 0.2394 berhu: 0.1022 grad: 0.0942 norm: 0.0087 mrel: 0.0385	rmse: 0.1543 berhu: 0.0659 grad: 0.0823 norm: 0.0066 mrel: 0.0202	0.25模型 只在NYU和人数据上训练
9 mobilenet-v1-quant-128x160-conv_dw0.25-upcat-suncg-general	rmse: 0.5903 berhu: 0.3480 grad: 0.0894 norm: 0.0096 mrel: 0.1414	rmse: 0.2394 berhu: 0.1022 grad: 0.0942 norm: 0.0087 mrel: 0.0385	rmse: 0.1543 berhu: 0.0659 grad: 0.0823 norm: 0.0066 mrel: 0.0202	同8 在新数据上训练
10 mobilenet-v1-quant-128x160-conv_dw0.25-reverse	rmse: 0.5835 berhu: 0.3969 grad: 0.0702 norm: 0.0069 mrel: 0.1797	rmse: 0.2957 berhu: 0.1566 grad: 0.0867 norm: 0.0080 mrel: 0.0634	rmse: 0.2163 berhu: 0.1090 grad: 0.0769 norm: 0.0063 mrel: 0.0349	同9 减少layer3卷积次数, 压缩d
11 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw	rmse: 0.4806 berhu: 0.2749 grad: 0.0736 norm: 0.0078 mrel: 0.1081	rmse: 0.1920 berhu: 0.0810 grad: 0.0755 norm: 0.0068 mrel: 0.0326	rmse: 0.1455 berhu: 0.0677 grad: 0.0731 norm: 0.0058 mrel: 0.0204	219M模型 全部数据训练
12 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-person	rmse: 0.4793 berhu: 0.2658 grad: 0.0750 norm: 0.0079 mrel: 0.1017	rmse: 0.1923 berhu: 0.0837 grad: 0.0767 norm: 0.0069 mrel: 0.0335	rmse: 0.1485 berhu: 0.0696 grad: 0.0738 norm: 0.0058 mrel: 0.0211	同11 全人数据训练
13 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-top	rmse: 0.4723 berhu: 0.2687 grad: 0.0734 norm: 0.0078 mrel: 0.1067	rmse: 0.1909 berhu: 0.0805 grad: 0.0753 norm: 0.0068 mrel: 0.0326	rmse: 0.1466 berhu: 0.0670 grad: 0.0727 norm: 0.0057 mrel: 0.0203	同11 全数据 增加top层
14 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-inv-norm	rmse: 0.7018 berhu: 0.4217 grad: 0.0871 norm: 0.0088 mrel: 0.1567	rmse: 0.2575 berhu: 0.1166 grad: 0.0952 norm: 0.0088 mrel: 0.0422	rmse: 0.2068 berhu: 0.0934 grad: 0.0917 norm: 0.0080 mrel: 0.0272	同11 全数据 采用0.9分位数进行逆深度
15 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-pixel-shuffle	rmse: 0.5282 berhu: 0.3114 grad: 0.0868 norm: 0.0090 mrel: 0.1231	rmse: 0.1971 berhu: 0.0896 grad: 0.0864 norm: 0.0078 mrel: 0.0369	rmse: 0.1645 berhu: 0.0716 grad: 0.0827 norm: 0.0069 mrel: 0.0221	同11 全数据 采用pixelshuffle代替上采样

通过上述实验可以发现

(1) 在新数据上小模型的损失也可以达到大模型的结果, 这是因为限定了0-6分布比较集中的数据, 因此可以说明的是模型越小, 所能预测的深度分布越有限, 后续将验证模型对那些分布的数据较好和较差。

(2) 大模型在全数据上的结果和之前几乎一样, 模型效果已经很难再提升, 需要再借助其他方法进行优化, 如同时出法向量和深度, 互相refine。

12.18-25

model	nyu	CAD	URFall	config
0 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-top	rmse: 0.4723 berhu: 0.2687 grad: 0.0734 norm: 0.0078 mrel: 0.1067	rmse: 0.1909 berhu: 0.0805 grad: 0.0753 norm: 0.0068 mrel: 0.0326	rmse: 0.1466 berhu: 0.0670 grad: 0.0727 norm: 0.0057 mrel: 0.0203	同11 全数据 增加top层
	rmse: 0.4360 berhu: 0.2348 grad: 0.0730 norm: 0.0078 mrel: 0.0911	rmse: 0.1671 berhu: 0.0611 grad: 0.0696 norm: 0.0057 mrel: 0.0246	rmse: 0.1237 berhu: 0.0498 grad: 0.0686 norm: 0.0052 mrel: 0.0143	同0 SGD+nesterov
1 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-inv-norm	rmse: 0.4806 berhu: 0.2749 grad: 0.0736 norm: 0.0078 mrel: 0.1081	rmse: 0.1920 berhu: 0.0810 grad: 0.0755 norm: 0.0068 mrel: 0.0326	rmse: 0.1455 berhu: 0.0677 grad: 0.0731 norm: 0.0058 mrel: 0.0204	同上表14 基于11 finetune
2 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-general	rmse: 0.6116 berhu: 0.3390 grad: 0.0816 norm: 0.0084 mrel: 0.1220	rmse: 0.2272 berhu: 0.0944 grad: 0.0909 norm: 0.0081 mrel: 0.0365	rmse: 0.2301 berhu: 0.0918 grad: 0.0857 norm: 0.0074 mrel: 0.0259	100M 通用模型
3 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-reduce-layer3	rmse: 0.5084 berhu: 0.3022 grad: 0.0738 norm: 0.0079 mrel: 0.1206	rmse: 0.2041 berhu: 0.0911 grad: 0.0762 norm: 0.0071 mrel: 0.0374	rmse: 0.1588 berhu: 0.0783 grad: 0.0737 norm: 0.0061 mrel: 0.0247	193M 减少layer3卷 积次数
4 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-reduce-layer3-top	rmse: 0.5012 berhu: 0.2993 grad: 0.0741 norm: 0.0078 mrel: 0.1184	rmse: 0.1999 berhu: 0.0891 grad: 0.0762 norm: 0.0070 mrel: 0.0357	rmse: 0.1556 berhu: 0.0745 grad: 0.0739 norm: 0.0060 mrel: 0.0229	同上 加top层
5 mobilenet-v1-quant-128x160-conv_dw0.5-sum-suncg-person	rmse: 0.5014 berhu: 0.2891 grad: 0.0754 norm: 0.0079 mrel: 0.1133	rmse: 0.2190 berhu: 0.0999 grad: 0.0849 norm: 0.0076 mrel: 0.0409	rmse: 0.1782 berhu: 0.0853 grad: 0.0816 norm: 0.0067 mrel: 0.0261	同2 纯人模型
6 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-top-l1	rmse: 0.4380 berhu: 0.2341 grad: 0.0773 norm: 0.0082 mrel: 0.0901	rmse: 0.1648 berhu: 0.0586 grad: 0.0752 norm: 0.0065 mrel: 0.0238	rmse: 0.1267 berhu: 0.0471 grad: 0.0727 norm: 0.0057 mrel: 0.0137	同0 加L1正则项 SGD+nesterov

7 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-top-new	rmse: 0.4332 berhu: 0.2230 grad: 0.0802 norm: 0.0086 mrel: 0.0846	rmse: 0.1561 berhu: 0.0554 grad: 0.0771 norm: 0.0066 mrel: 0.0223	rmse: 0.1260 berhu: 0.0474 grad: 0.0739 norm: 0.0058 mrel: 0.0137	同0 用新loss SGD+nesterov
8 mini-depth	rmse: 0.5929 berhu: 0.3370 grad: 0.0924 norm: 0.0093 mrel: 0.1310	rmse: 0.2210 berhu: 0.0865 grad: 0.0981 norm: 0.0087 mrel: 0.0340	rmse: 0.1584 berhu: 0.0629 grad: 0.0900 norm: 0.0071 mrel: 0.0187	66M songtao小模型 SGD+nesterov
9 mobilenet-v1-quant-128x160-conv_dw0.5-srfl-ultimate-no-se-float-dw-upcat	rmse: 0.4484 berhu: 0.2446 grad: 0.0789 norm: 0.0081 mrel: 0.0939	rmse: 0.2050 berhu: 0.0822 grad: 0.0929 norm: 0.0084 mrel: 0.0330	rmse: 0.1566 berhu: 0.0646 grad: 0.0863 norm: 0.0071 mrel: 0.0189	129M base SGD+nesterov
10 base-top	rmse: 0.4504 berhu: 0.2496 grad: 0.0723 norm: 0.0075 mrel: 0.0962	rmse: 0.2245 berhu: 0.0931 grad: 0.0834 norm: 0.0072 mrel: 0.0377	rmse: 0.1682 berhu: 0.0726 grad: 0.0793 norm: 0.0062 mrel: 0.0214	同9 加top层
11 mobilenet-prune	rmse: 0.4403 berhu: 0.2342 grad: 0.0801 norm: 0.0084 mrel: 0.0907	rmse: 0.1652 berhu: 0.0588 grad: 0.0789 norm: 0.0070 mrel: 0.0241	rmse: 0.1307 berhu: 0.0508 grad: 0.0757 norm: 0.0060 mrel: 0.0152	同0 剪枝模型
12 mobilenet-v1-quant-128x160-conv_dw-24-384-general	rmse: 0.6229 berhu: 0.3539 grad: 0.0813 norm: 0.0083 mrel: 0.1303	rmse: 0.2480 berhu: 0.0999 grad: 0.0959 norm: 0.0090 mrel: 0.0387	rmse: 0.1910 berhu: 0.0766 grad: 0.0888 norm: 0.0075 mrel: 0.0220	53M
13 base-160-pixelshuffle	rmse: 0.6061 berhu: 0.3628 grad: 0.0761 norm: 0.0082 mrel: 0.1450	rmse: 0.2185 berhu: 0.0844 grad: 0.0813 norm: 0.0071 mrel: 0.0344	rmse: 0.1531 berhu: 0.0567 grad: 0.0726 norm: 0.0054 mrel: 0.0166	同9 用pixelshuffle 上采样

从表中model 8可以发现，（1）单纯使用SGD(+nesterov)loss很难降下来，而使用RMSProp则可以使loss很快地收敛到一个比较低的水平，但是再继续优化基本不再变化，而使用SGD+nesterov虽然下降较慢，但是可以使loss达到一个更低的水平。

（2）增加top层普遍要原来模型要好，相当于模型增加了高层信息。

（3）使用新的loss函数可以达到目前最好的结果，甚至要比当前loss要更低。

12.25-1.7

model	nyu	CAD	URFall	config
0 mini-depth-small	rmse: 0.5755 berhu: 0.3354 grad: 0.0830 norm: 0.0086 mrel: 0.1312	rmse: 0.2536 berhu: 0.0976 grad: 0.0926 norm: 0.0088 mrel: 0.0388	rmse: 0.1734 berhu: 0.0702 grad: 0.0876 norm: 0.0074 mrel: 0.0205	detection模型 全数据 增加top层30M
1 base-normal	rmse: 0.4245 berhu_depth: 0.0110 berhu_normal: 0.2221 grad: 0.1244 norm: 0.0133 mrel: 0.0825	rmse: 0.5859 berhu_depth: 0.0601 berhu_normal: 0.2549 grad: 0.3690 norm: 0.0645 mrel: 0.1844	rmse: 0.6817 berhu_depth: 0.1044 berhu_normal: 0.3499 grad: 0.3635 norm: 0.0640 mrel: 0.1720	同上表9 出depth+normal 130M

2 base-edge	rmse: 0.4180 berhu: 0.2214 grad: 0.0790 norm: 0.0079 mrel: 0.0859	rmse: 0.1788 berhu: 0.0722 grad: 0.0893 norm: 0.0075 mrel: 0.0303	rmse: 0.1374 berhu: 0.0590 grad: 0.0835 norm: 0.0064 mrel: 0.0178	同121M
3 base-simple	rmse: 0.4785 berhu: 0.2608 grad: 0.0860 norm: 0.0087 mrel: 0.1003	rmse: 0.1848 berhu: 0.0724 grad: 0.0931 norm: 0.0083 mrel: 0.0284	rmse: 0.1431 berhu: 0.0569 grad: 0.0856 norm: 0.0069 mrel: 0.0166	上表9基础上减层 63M
4 base-ppsp	rmse: 0.5015 berhu: 0.2862 grad: 0.0858 norm: 0.0085 mrel: 0.1114	rmse: 0.1768 berhu: 0.0696 grad: 0.0902 norm: 0.0077 mrel: 0.0281	rmse: 0.1348 berhu: 0.0549 grad: 0.0836 norm: 0.0065 mrel: 0.0161	101M
5 base-simple-edge	rmse: 0.4692 berhu: 0.2568 grad: 0.0877 norm: 0.0087 mrel: 0.1001	rmse: 0.1787 berhu: 0.0709 grad: 0.0935 norm: 0.0083 mrel: 0.0284	rmse: 0.1401 berhu: 0.0562 grad: 0.0856 norm: 0.0069 mrel: 0.0165	同3 边界加权为5
6 base-simple-up-mask	rmse: 1.3693 berhu: 1.0128 grad: 0.0740 norm: 0.0086 mrel: 0.5163	rmse: 1.1460 berhu: 0.8459 grad: 0.0761 norm: 0.0084 mrel: 0.4574	rmse: 1.2248 berhu: 1.0577 grad: 0.0836 norm: 0.0081 mrel: 0.2826	同3 上采样加mask
7 base-simple-24	rmse: 0.5613 berhu: 0.3345 grad: 0.0893 norm: 0.0089 mrel: 0.1309	rmse: 0.2196 berhu: 0.0904 grad: 0.0964 norm: 0.0089 mrel: 0.0357	rmse: 0.1680 berhu: 0.0692 grad: 0.0886 norm: 0.0074 mrel: 0.0205	小模型 43M
8 base-simple-nike	rmse: 0.4785 berhu: 0.2608 grad: 0.0860 norm: 0.0087 mrel: 0.1003	rmse: 0.1848 berhu: 0.0724 grad: 0.0931 norm: 0.0083 mrel: 0.0284	rmse: 0.1431 berhu: 0.0569 grad: 0.0856 norm: 0.0069 mrel: 0.0166	同3 新loss函数
9 base-edge-10	rmse: 0.4160 berhu: 0.2200 grad: 0.0807 norm: 0.0081 mrel: 0.0848	rmse: 0.1718 berhu: 0.0679 grad: 0.0899 norm: 0.0075 mrel: 0.0280	rmse: 0.1327 berhu: 0.0556 grad: 0.0838 norm: 0.0064 mrel: 0.0167	同2 边界加权10
10 base-simple-edge-10	rmse: 0.4682 berhu: 0.2575 grad: 0.0891 norm: 0.0088 mrel: 0.1005	rmse: 0.1793 berhu: 0.0739 grad: 0.0942 norm: 0.0083 mrel: 0.0298	rmse: 0.1438 berhu: 0.0611 grad: 0.0864 norm: 0.0070 mrel: 0.0181	同5 边界加权10